Hashgraph-inspired consensus flavors

Abstract:

Ниже мысли, пришедшие в голову после просмотра и (наконец) понимания видео:

Dr. Leemon Baird: How Hashgraph Works - A Simple Explanation w/ Pictures

https://www.youtube.com/watch?v=wgwYU1Zr9Tg

Ключ к (не)полному пониманию видоса для меня был в timecode 28:22 - на том слайде ключевая информация о 'round created', которую почему-то не озвучивают и толком не объясняют; однако на слайде можно прочитать, хоть и в минималистичном виде.

А также после того, ка я выяснил, что сам алгоритм распространяется под лицензией Apache 2.0, то есть можно сделать свою имплементацию и модифицировать как захочешь.

см: https://docs.hedera.com/hedera/core-concepts/hashgraph-consensus-algorithms

или же мой пруф-форк здесь:

https://github.com/codekrolik2/hedera-docs/blob/master/core-concepts/hashgraph-consensus-algorithms/README.md

---

Hashgraph это довольно сложный алгоритм, и многие из движущихся частей можно если и не заменить, то определенно потвикать по следующим причинам:

- Алгоритм не настаивает ни на каких низкоуровневых деталях имплементации, то есть настолько, насколько все вводные, описанные в алгоритме соблюдаются, (или их эквиваленты) имплементировать можно миллионом разных способов.
- Улучшение производительности - более простой траверс последовательностей событий, фильтрация получаемой информации, и пр.;
- Упрощение структур/утилитарных алгоритмов при использовании алгоритма в доверенном пространстве, например если мы создаем кластерную БД и все ноды по определению принадлежат нам;
- Возможность наблюдения за поведением системы с разными настройками протокола

Их ранние презентации ссылаются на некую легендарную (т.к. о ней слышали только в легендах) программу HashgraphDemo app (в вышеупомянутом видео таймкод 51:17), но найти ее я так и не смог, поэтому надо запилить свою не только потому, что хотелось бы сделать кучу всяких крутилок и переключателей, чтобы тестировать алгоритм, но и так как оригинальная программа если и может быть найдена (чего мне не удалось), то наверное существует без поддержки в заброшенном виде, и похоже, что ее публикацию посчитали за бизнес-ошибку и теперь пытаются это скрыть, к тому же она заточена явно на базовый алгоритм и блокчейн, а хотелось бы также поиграться со своими идеями и расширениями; в общем, 100 причин чтобы не тратить больше времени на ее поиск.

Bottomline - пилим свою HashgraphDemo и свою имплементацию алгоритма, с игрой 21 и гейшами.

По структуре самого event - их можно разделить на 2 группы

1. Эвенты, содержащие данные, т.е. например для блокчейна это транзакции. Назовем упрощенно data/new.
2. Эвенты без данных, содержащие лишь информацию о распространении госсипа. Назовем упрощенно gossip/reference.

По идее сами данные не обязательно эмбеддить в структуру эвента, это могут быть какие-нибудь референсы типа id объектов во внешнем хранилище, и сэкономить на траффике распространения госсипа.

Event-ы и как я их вижу.

Рассмотрим структуру эвента, которую они показывают в видосе:

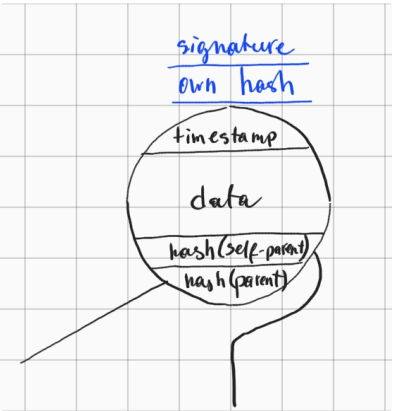

То, что черным - есть на картинке в видосе, а то, что синим - они об этом говорят, но почему-то остается впечатление, что не считают это частью event-а, по непонятным причинам.

Если мы вдумаемся в то, что же такое `self-parent-hash`, `other-parent-hash` и `own-hash`, то станет понятно, что это не что иное, чем уникальный идентификатор event-а и ссылка на предыдущие event-ы по их идентификаторам. Это имеет свои плюсы, т.к. id жестко приаттачен к данным, т.е. выполняет также роль чексуммы (как и любой hash), но имеет и свои недостатки - например, не является монотонно растущими и не содержит другой метаинформации, например, отсылка на родителя. Поэтому, навскидку, для выяснения откуда конкретный event взялся, нужны будут лукапы, а для получения последовательности эвентов от конкретной ноды - траверс графа, так как таймстемпы могут совпадать (а кроме того, если я правильно понял, ничто таймстемпам не мешает еще и скакать взад-вперед, причем на отдельно взятой ноде, таким образом не гарантируя формирования упорядоченной последовательности).

Помимо того, вспомним, что и у хешей в теории могут быть коллизии, например md5.

Из жизни: один мой бывший коллега как-то раз написал систему, где использовал в качестве первичного ключа md5 хеш, и они у него таки совпали в проде, что оказало влияние на его настроение в тот момент - тут надо заметить, что он решил эту проблему, поменяв один хеш md5 на несколько, типа комбинация md5+sha1 или что-то там еще, но когда я ему сказал - а почему бы не использовать нормальные уникальные id, то посмотрел на меня как на мудака, что-то пренебрежительно бросил про вероятности и пресек развитие темы; в общем, я так и не понял, чего же я такого сказал неправильного 🙂 При этом, справедливости ради, следует заметить, что после этого фикса у него больше не происходило коллизий. Возможно, что и в Heder-е у них тоже не будет коллизий, возможно, что даже никогда. Такая вероятность, безусловно, существует.

Но перейдем к практическому вопросу - незаменим ли в таком случае хэш? и нельзя ли его заменить на пару id/checksum? - и появляется такая мысль, что если мы в небезопасном окружении типа блокчейна, где есть ноды, от которых можно ожидать отсылку всякой дичи, лишь бы сломать всю распределенную систему, то могут быть преимущества в том, что наш id крепко завязан с данными, т.к. значительно сложнее будет начать генерировать какие-то злонамеренно сформированные или дублированные hash, нежели id. В то же время в ситуации “собственный кластер БД” можно соптимизировать на том, чтобы не выполнять трудоемкое вычисление hash, и при этом добавить полезные свойства, как - референс на ноду-создателя, свойство монотонного прироста значения, и т.п.

Также, для оптимизации производительности локального доверенного кластера мы можем отказаться и от полноценой криптографической подписи, например, если вделаем создателя в айдишник - и это тоже экономия вычислительных ресурсов.

Замечу, что как было показано выше (или же я попытался, как мог), алгоритм Hashgraph (во всяком случае теоретически) может быть реализован без использования хеш-функций. Засчитываем это, как каламбур.

Если заменить все-таки hash на id, то можно называть более понятно (according to me)

`own-hash`	`id` or `event_id`
`self-parent-hash`	`previous_event_id` - если представить эвенты, исходящие с одной ноды, как связный список, то структура этого списка формируется именно этим полем.
`other-parent-hash`	`@Nullable outer_event_id` - референс на порождающий эвент извне, принадлежащий последовательности id, существующей на другой ноде.

О parent-референсах

Очевидно, что помимо самого первого события (появления ноды), у всех последующих событий ноды всегда будет `self-parent`.

При этом не совсем понятно, может ли быть такая ситуация, когда `other_parent IS NULL`. Если посмотреть их видос выше, то в их представлении графа нет таких нод, у которых бы был только `self-parent`, а `other-parent` бы отсутствовал. Я не знаю, с чем это связано, в том числе еще туману напускает тот факт, что у них на той диаграмме непонятно в каком эвенте есть данные, а в каком нет, но наверное, какие-то данные там все же где-то должны быть.

Лично мое видение этого алгоритма в том, что у любого события `data/new` всегда будет только `self-parent`, и никогда не будет `other-parent`. Возможно, их имплементация оперирует на иных предпосылках, а значит у них неправильно. (*“неправильно” as in - не так, как будет у нас*).

К примеру, почему это вдруг я не могу просто взять и создать данные, а должен ждать какого-то там события госсип от кого-то там, да даже если оно и приходит часто и регулярно, зачем, вообще, это делать частью создания данных. Мне думается, лучше будет так: надо создать данные - взял и создал, вот сам и отправляй госсип другим, так явно и проще, и понятнее, и быстрее.

Подобную discrepancy со стороны их диаграммы/реализации просто игнорируем, и реализуем так, как видим сами.

Монотонно прирастающие id, групповые версии и их роль в оптимизации получения изменений графа при госсип-обменах

Если мы меняем хеши на монотонно прирастающие id, а также учитывая, что мы имеем дело с группой источников (в данном случае нод), каждая из которых генерирует свою собственную последовательность объектов/событий идентифицирующихся монотонно растущими ключами, то это позволяет использовать идею о групповых версиях из моей более ранней работы VUnion. Использование групповых версий позволит соптимизировать получение подграфов при госсип-обменах - путем вытаскивания хвостов последовательностей для каждого из источников, начиная с версии, фигурирующей в групповой версии госсип-партнера по обмену. Если локально хранить данные последовательности событий, как и в VUnion, в упорядоченном виде, то можно быстро вычислять и отправлять хвосты этих последовательностей начиная с любой конкретной версии; таким образом групповая версия будет служить идентификатором общего состояния локального образа графа.

Больше подробностей о групповых версиях в доке VUnion.

Транзиентность структуры эвентов при использовании в БД и KeyValue storages

Скорее всего, для целей блокчейна Hedera, им нужно хранить весь gossip-граф в первозданном виде, по тем же причинам, связанным с недоверием и пр., по которым хранят все записи блокчейна в том виде, в котором они их заперсистили и все остальные блокчейн-системы, начиная с Bitcoin. (*Disclaimer - предполагаю насчет Hedera, и могу ошибаться, но это не меняет сути сказанного ниже*).

В то же время, если применять Hashgraph-подобные алгоритмы в традиционных базах данных, хранить весь этот госсип непринципиально. В данном случае нам будет важно хранить только лишь результат этого госсипа - а именно, единую последовательность data-объектов из соответствующих data-эвентов. Как только все согласились на полную последовательность

того или иного раунда для всех его эвентов, весь связанный с этим госсип можно просто дропнуть, в результате мы получим что-то вроде transaction log, состоящий из последовательности содержимого data-эвентов.

Также, в случаях, когда нам ценны максимально дата-эвенты, а госсип-эвенты меньше, один из вариантов оптимизации госсипа при помощи групповой версии - это привязка групповой версии к decided и undecided дата-эвентам, а не к госсип-эвентам. В таком случае, если инициируется госсип-раунд, можно будет избежать ненужного размножения новых эвентов, т.к. групповая версия будет точно указывать на то, что информации о новых undecided дата-эвентах в госсипе не будет, а тогда и госсип незачем инициировать. Говорить-то не о чем.

Стратегия восстановления данных на старте data storage ноды после краха или простоя в таком случае могла бы состоять из подтягивания хвоста decided дата-эвентов (aka transaction log), и затем включения ноды в текущий госсип.

Прочие оптимизации в условиях доверенного кластера

Для доверенных кластеров,

- Все места, где мы используем что-то вроде XOR-инга хеша с общеизвестным рандомным значением и использование определенных битов результата для определения точной последовательности эвентов при коллизиях, можно изменить на систему, где мы держим все ноды в circular buffer, который и определяет приоритет, и каждый новый раунд мы отправляем его голову в хвост, для баланса.
- Также (IMO) в доверенном кластере можно все места в алгоритме, где мы используем supermajority просто заменить на кворум. Чую, но четко обосновать пока не могу (нужен матан).